

Clasificación Robusta de Señales de Tráfico mediante Redes Convolucionales y Aumentación de Datos de Alta Fidelidad.

El proyecto se centró en desarrollar un **clasificador robusto** de señales de tráfico (Pare, Ceda el Paso, Semáforo) mediante la optimización de la fase de aumentación de datos. Se estableció una **división estricta 80/20 (Train/Test)** para garantizar la integridad de la validación. La aumentación fue diseñada para simular fielmente condiciones reales (zoom, ruido, contraste) en lugar de deformaciones geométricas. El modelo CNN resultante, entrenado con Teachable Machine, demostró un **alto desempeño** al ser evaluado con métricas formales, alcanzando un **F1-Score ponderado de 0.88**. Este éxito valida la capacidad del sistema para integrarse eficientemente en **sistemas ADAS** (Asistencia Avanzada al Conductor).

Objetivos del Proyecto

- **Objetivo General:** Desarrollar un modelo de clasificación de señales de tráfico basado en Visión Artificial con un F1-Score superior al 0.85.
- **Objetivos Específicos:**
 - Crear un *dataset* robusto mediante aumentación que simule variaciones fotométricas y de perspectiva realistas.
 - Garantizar la integridad de la evaluación mediante una división estricta de datos (Train/Test).
 - Validar el modelo usando métricas formales (Precisión, Exhaustividad, F1-Score).

Metodología y Arquitectura

La metodología se centró en la calidad de los datos para garantizar la robustez del modelo:

Estructura y Preparación de Datos

El *dataset* base se organizó en tres clases (**Pare, Ceda el Paso, Semáforo**).

- **División:** 80% Entrenamiento (train) y 20% Prueba (test).
- **Dataset Final:** El set de entrenamiento se expandió a **9 imágenes por muestra original** mediante aumentación, y el set de prueba se mantuvo **puro** (solo copias originales redimensionadas).

Estrategia de Aumentación (HD, Sin Rotación)

Se utilizó código Python (Pillow/NumPy) para generar **8 variantes** por imagen, eliminando la rotación por los artefactos de fondo.

Técnica Aplicada	Variantes	Propósito en la Conducción
Brillo y Contraste	4	Simula condiciones de luz extremas y sombras.
Zoom Central	2	Simula el acercamiento del vehículo a la señal.
Desenfoque y Ruido	2	Simula velocidad o baja calidad de cámara (noche).

Arquitectura y Entrenamiento

- **Modelo Base:** Red Convolucional (CNN) **MobileNetV2**.
- **Técnica: Transferencia de Aprendizaje**, adaptando el conocimiento previo del modelo a la clasificación de las tres señales.
- **Implementación:** Teachable Machine (para entrenamiento) y TensorFlow/Keras (para evaluación).

Resultados y Evaluación Formal

El modelo fue evaluado automáticamente en Google Colab, corrigiendo el desfase de índices con el archivo labels.txt.

Métricas Clave

El modelo fue validado con éxito, confirmando un desempeño superior al objetivo:

Métrica	Resultado	Interpretación
Exactitud (Accuracy)	0.88	88% de aciertos generales en el set de prueba.
F1-Score Ponderado	0.88	Métrica crucial que confirma el balance entre precisión y detección.
Precision Máxima	0.95 (Clase Semáforo)	La predicción más confiable del modelo.

Análisis de Confusión

El error principal se concentró en la distinción entre dos formas geométricas.

- **Punto Débil:** La Precisión de "Pare" es **0.82**, el valor más bajo. La Matriz de Confusión reveló que el modelo confundió "Ceda el paso" con "Pare" en varias instancias.

6. Conclusión y Proyección

El sistema de clasificación CNN logró un **F1-Score robusto de 0.88**, validando la estrategia de aumento de datos por brillo y zoom. El modelo clasifica con alta precisión las tres señales principales, siendo apto para integrarse en **sistemas ADAS** gracias a su arquitectura ligera. Se proyecta mejorar el alcance expandiendo las clases y aplicando *Color Jitter* para simular el deterioro real de las señales.

Mejoras Propuestas (Foco en el Futuro)

1. **Object Detection:** Transicionar a un modelo tipo YOLO para no solo clasificar la señal, sino también determinar su **ubicación exacta** (bounding box) dentro del marco de video.
2. **Aumento por Color:** Integrar la técnica *Color Jitter* para simular el **desgaste y desvanecimiento** de los colores de las señales, mejorando la resistencia en infraestructuras antiguas.
3. **Expansión de Clases:** Incluir señales reglamentarias y preventivas adicionales para maximizar la utilidad del sistema en entornos de conducción complejos.